

	RÉPUBLIQUE TUNISIENNE MINISTÈRE DE L'ENSEIGNEMENT SUPÉRIEUR ET DE LA RECHERCHE SCIENTIFIQUE **** DIRECTION GENERALE DES ÉTUDES TECHNOLOGIQUES **** INSTITUT SUPÉRIEUR DES ÉTUDES TECHNOLOGIQUES DE CHARGUIA **** Département Technologies de l'Informatique	
---	--	---

RAPPORT

De

Projet de Fin d'Études

Licence Appliquée en Technologies de l'Informatique
Parcours : Développement de système d'information

Sujet :

Titre de votre projet de fin d'études

Elaboré par

Maali Salsabil
&
Abidi Ameni

Encadré par :

M. Ben Jaffel Zied
M. Houssem

Société d'accueil : Centre informatique de ministère de finances

Année Universitaire : 2025/2026

Table des matières

Introduction générale	1
Chapitre 1 :Cadre général de projet	2
I Présentation de l'organisme d'accueil	2
I.1 présentation générale de l'entreprise	2
II Contexte et enjeux	2
III Etude de l'existant	3
III.1 Description de l'existant	3
III.2 Critique de l'existant	3
III.3 Problématique	4
III.4 Solution proposé	4
IV Périmètre fonctionnel et contraintes	5
IV.1 Besoins fonctionnels	6
IV.2 Besoins non fonctionnels	9
V Choix techniques généraux	9
V.1 Environnement matériel	9
V.2 Environnement logiciel	10
Chapitre 2 :État de l'art	16
I Chatbot Intelligent	16
I.1 Définition et Concepts fondamentaux	16
I.2 Chatbot classique et Chatbot intelligent	16
I.3 Comparaison des différentes types de Chatbots et de leur évolution technologique	17
II Approche Auto-hébergée	18
II.1 Définition de l'approche auto-hébergée	18
II.2 Comparaison entre Auto-hébergée et Cloud	19
III Modèles de langage de grande taille (LLM)	19
III.1 Définition des LLM	19
III.2 Entraînement des modèles de langage LLM	20
III.3 Fonctionnement des modèles de langage LLM	20

III.4	Présentation des principaux modèles de langage (LLM)	21
III.5	Utilisation des LLM dans les systèmes conversationnels	22
IV	RAG(Retrieval-Augmented Generation)	23
IV.1	Définition du RAG	23
IV.2	Principe de fonctionnement d'un système RAG	24
IV.2.1	Requête utilisateur	24
IV.2.2	Recherche documentaire (Retrieval)	24
IV.2.3	Génération de la réponse (Generation)	24
IV.3	Composants d'un système RAG	25
IV.3.1	Les documents	25
IV.3.2	Les embeddings	25
IV.3.3	La base vectorielle	25
IV.3.4	Le LLM (Large Language Model)	25

Table des figures

1	Logo FastAPI	11
2	Logo React	11
3	Logo Tailwind	11
4	Logo Python	12
5	Logo Javascript	12
6	Logo de Typescript	12
7	Logo de MongoDB	13
8	Logo de Qdrant	13
9	Logo d'Ollama	13
10	Logo de llama3	13
11	Logo de VS Code	14
12	Logo de Trello	14
13	Logo de Notion	14
14	Logo de Wireframe	14
15	Logo de Draw.Io	14
16	Logo de Docker	15
17	Logo de Ubuntu	15
18	Entraînement des modèles de langage (LLM)	20
19	Fonctionnement des modèles de langage LLM	21
20	Logo ChatGPT	21
21	Logo Claude	22
22	Logo Claude	22
23	Shéma de fonctionnement d'un système RAG	24

Liste des tableaux

1	Environnement matériel	10
2	Framework et bibliothèque	11
3	Les Langages de Programmation	12
4	Les outils de base de données	13
5	Outil d'IA	13
6	Outils de développement	14
7	Outils de modélisations et conception	14
8	Outils de conteneurisation et système d'exploitation utilisés	15
9	Différence entre Chatbot classique et Chatbot intelligent	17
10	Evolution des Chatbots : de ELIZA à ChatGPT	18
11	Comparaison entre l'approche auto-hébergée et l'approche Cloud	19
12	Comparaison des modèles de langage ChatGPT, Claude et LLaMA	23

Introduction générale

Chapitre 1 : Cadre général de projet

Plusieurs possibilités peuvent être envisagées pour ce premier chapitre. Une des possibilités couramment adoptée consiste à présenter d'abord la société où s'est déroulé le PFE, effectuer par la suite une étude de l'existant sur les modalités de travail actuelles et justifier la méthodologie adoptée par l'étudiant.

I Présentation de l'organisme d'accueil

I.1 présentation générale de l'entreprise

Le **Centre Informatique du Ministère des Finances(CIMF)** joue un rôle fondamental dans l'administration publique tunisienne en gérant l'ensemble des systèmes d'information utilisés par les ministères et les institutions publiques. Il est responsable de la gestion et de l'optimisation des infrastructures technologiques qui soutiennent les différents services publics. Une de ses missions majeurs est d'assurer la sécurité numérique au sein de l'administration , en mettant en place des solutions de protection des données et en gérant les certificats électroniques utilisés pour l'authentification et la signature des transactions administratives.

Le CIMF supervise également le développement , le déploiement et la maintenance des applications et plateformes utilisées par les ministères , afin de garantir leur bon fonctionnement et leur conformité aux normes de sécurité. En parallèle , il offre une assistance technique aux utilisateurs et fournit des formations sur l'utilisation des outils numériques. En coordonnant divers projets de digitalisation des services publics , le CIMF contribue activement à l'amélioration de l'efficacité , de la transparence et de la modernisation des processus administratifs, soutenant ainsi les efforts de gouvernance numérique du gouvernement tunisien.

II Contexte et enjeux

Dans les administrations financières publiques, les documents juridiques et réglementaires jouent un rôle central dans le travail quotidien des agents. Ces documents, tels que les lois, décrets et circulaires , servent de base à la prise de décision et à l'application des règles administratives.

Cependant, avec l'augmentation continue du volume et de la diversité de ses documents complique leur gestion. La recherche d'informations pertinents devient souvent longue et laborieuse, ce qui peut entraîner une perte de temps significative pour les agents.

Cette situation soulève plusieurs enjeux majeurs. Elle peut affecter la productivité des utilisateurs, accroître le risque d'erreurs dans l'interprétation des textes et impacter la qualité des décisions prises.

Il est donc indispensable d'améliorer l'accès à l'information et de faciliter l'exploitation de ces documents tout en garantissant un environnement sécurisé

III Etude de l'existant

Cette partie comprend, généralement trois parties .

III.1 Description de l'existant

Actuellement , la gestion et l'exploitation des documents juridiques et réglementaires au sein des institutions financières publiques reposent principalement sur des méthodes traditionnels. Les documents utilisés sont de nature variée et comprenant notamment :

- Les lois et de finances ,
- Les décret et arrêtés d'application,
- Les circulaires et notes explicatives,
- Les décisions et interprétations juridiques,
- Les FAQ internes et documents de références.

Ces documents sont généralement stockés sous forme de fichiers PDF, Word ou de documents numérisés. Ils sont répartis entre des serveurs internes , des dossiers partage , des bases d'archive physique ou des plateformes intarnet . L'accès à l'information s'effectue essentiellement par une consultation manuelle des documents ou par une recherche simple basée sur des mots-clés et une organisation hiérarchique des dossiers.

Ainsi, malgré la richesse et la diversité des ressources documentaires disponibles , leur exploitation demeure complexe , peu structurée et fortement dépendante de l'intervention humaine.

III.2 Critique de l'existant

Bien que les méthodes actuelles présentent l'avantage d'un stockage centralisé minimale et d'un accès contrôlé aux documents, elles souffrent de plusieurs limites importantes qui réduisent leur efficacité.

Ces limites se manifestent notamment par :

- Le volume très élevé des documents juridiques et réglementaire , rendant leur consultation manuelle lente et peu efficace ,
- L'absence d'une solution automatique de collecte , de structuration et d'indexation intelligente des documents,
- Une recherche essentiellement basée sur mots-clés , sans prise en compte du contexte juridique ni des relations entre les textes ,
- Une difficulté à retrouver rapidement des réponses précises à des questions complexes ou transversales ,
- Une dépendance excessive à l'expertise individuelle, ce qui peut entraîner des erreurs d'interprétation ou des incohérences,
- L'absence d'outils d'extraction automatique de connaissance à partir des documents existants

De plus, les solutions cloud basés sur des services d'IA externes ne sont généralement pas adoptés au contexte des administrations publiques, en raison des contraintes liées à la confidentialité des données, à la souveraineté nationale et à la sécurité des informations sensibles.

III.3 Problématique

Face à l'augmentation continue du nombre de documents juridiques et réglementaires, ainsi qu'à leur complexité croissante, les méthodes traditionnelles de recherche et de consultation atteignent leurs limites. Les agents et les décideurs rencontrent des difficultés à accéder rapidement à une information fiable , contextualisée et à jour, ce qui peut impacter la qualité des décisions administratives et la conformité réglementaire.

L'absence d'une solution intelligente capable de collecter, structurer, indexer et exploiter automatiquement des documents constitue en frein majeur à la valorisation du capital informationnel existant. Par ailleurs, les contraintes de sécurité et de confidentialité excluent le recours à des solutions cloud externes .

La problématique centrale à laquelle répond ce projet peut donc être formulée comme suit :

Comment concevoir une solution intelligente, sécurisée et hébergée localement permettant la collecte, l'indexation et l'extraction de connaissances à partir d'un volume massif de documents juridiques et réglementaires, afin d'offrir une assistance conversationnelle fiable et contextualisée dans le domaine des finances publiques ?

III.4 Solution proposé

Pour répondre à cette problématique, le projet propose la mise en place d'un chatbot intelligent auto-hébergé basé sur un pipeline **RAG(Retrieval Augmented Genera-**

tion). Cette approche permet de combiner la puissance des modèles de langage avec une base documentaire contrôlée et fiable.

La solution proposée repose sur les axes suivants :

- **Collecte et structuration des documents** : automatisation de l'ingestion des documents juridiques et réglementaires, conversion en formats exploitables et classification par type et par thématique ,
- **Indexation vectorielle** : transformation des documents en embeddings sémantiques et stockage dans une base vectorielle afin de permettre une recherche contextuelle efficace,
- **Pipeline RAG** : récupération des passages pertinents à partir de la base documentaire et génération de réponses par un modèle de langage (**LLM**) open source hébergé localement,
- **Chatbot conversationnel** : interface web permettant aux utilisateurs de poser des questions en langage naturel et d'obtenir des réponses basées exclusivement sur les documents internes,
- **Sécurité et souveraineté** : déploiement local sécurisé sans dépendance à des services cloud externes,
- **Evaluation des performances** : mesure de la précision, de la pertinence et du temps de réponse du système.

Cette solution vise à transformer une base documentaire statique en une véritable source de connaissance exploitable en temps réel.

IV Périmètre fonctionnel et contraintes

La solution proposée implique plusieurs acteurs qui interagissent avec le système dans le cadre de son utilisation et de sa gestion. Ces acteurs représentent les différents profils d'utilisateurs qui exploitent l'application selon leurs besoins et leurs responsabilités au sein des administrations financières publiques.

- **Administrateur** : Il est responsable de la gestion globale du système. Il assure l'importation et la gestion des documents juridiques, supervise l'indexation, contrôle les activités des utilisateurs, gère les réclamations et garantit la sécurité ainsi que la traçabilité des opérations,
- **Utilisateur (agent financier)** : Il utilise le système pour effectuer des recherches, poser des questions en langage naturel via le chatbot et exploiter les informations dans le cadre de ses tâches quotidiennes. Il peut également gérer ses conversations et soumettre des réclamations si nécessaire.

IV.1 Besoins fonctionnels

- **Gestion des documents :**

- **Importation es documents :**

- L’administrateur peut importer des documents juridiques sous formats PDF ou Word ,
 - Le système peut nettoyer automatiquement les documents importés,
 - Le système peut découper les documents en segments pertinents et les vectoriser,
 - Le système peut préremplir automatiquement le titre du document,
 - L’administrateur peut sélectionner une catégorie lors de l’importation,
 - L’administrateur peut visualiser les documents avant validation,
 - L’administrateur peut suivre la progression de l’indexation,
 - L’administrateur peut annuler l’indexation d’un document.

- **Consultation des documents :**

- L’administrateur peut consulter la liste des documents indexés,
 - L’administrateur peut consulter les détails d’un document,
 - L’administrateur peut filtrer les documents par catégorie ou status
 - L’administrateur peut réinitialiser les filtres,
 - L’administrateur peut rechercher un document par son titre,
 - L’administrateur peut exporter la liste des documents en PDF ou Excel,
 - L’utilisateur peut filtrer les documents par catégorie ou date

- **Gestion des documents :**

- L’administrateur peut modifier les informations d’un document indexé ,
 - L’administrateur peut supprimer un document de la base vectorielle.

- **Recherche et consultation intelligente :**

- **Interaction intelligente (Chatbot) :**

- L’utilisateur peut poser une question en langage naturel,
 - Le système analyse la question et retourne une réponse basée sur les documents indexés,
 - La réponse est générés à partir des contenus les plus pertinents de la base documentaire.

- **Recherche par mots-clés :**

- L’utilisateur peut effectuer une recherche en saisissant un ou plusieurs mots-clés,

- Le système affiche les documents contenant les termes recherchés avec mise en évidence,
 - L'utilisateur peut consulter ses dernières recherches.
- **Résultats de recherche :**
 - L'utilisateur peut visualiser la liste des documents trouvés,
 - Le système met en évidence les passages contenant les termes recherchés,
 - L'utilisateur peut consulter un aperçu du document,
 - L'utilisateur peut consulter le document complet.
- **Gestion des documents issus de la recherche :**
 - L'utilisateur peut ajouter un document à ses favoris,
 - L'utilisateur peut consulter sa liste des favoris,
 - L'utilisateur peut retirer un document de ses favoris.
- **Gestion des conversations :**
 - **Consultation et organisation :**
 - L'utilisateur peut consulter, ses anciennes conversations,
 - L'utilisateur peut rechercher dans une conversation,
 - L'utilisateur peut renommer une conversation,
 - L'utilisateur peut supprimer une conversation.
 - **Archivage :**
 - L'utilisateur peut archiver et restaurer une conversation,
 - L'utilisateur peut consulter ses conversations archivées
 - **Actions sur les réponses :**
 - L'utilisateur peut copier une réponse,
 - L'utilisateur peut télécharger une réponse en PDF,
 - L'utilisateur peut exporter une conversation en PDF,
 - L'utilisateur peut choisir un mode de réponse court ou détaillé.
- **Gestion des comptes et sécurité :**
 - **Authentification :**
 - L'utilisateur peut se connecter,
 - L'utilisateur peut se déconnecter,
 - **Gestion du profil :**
 - L'utilisateur peut se modifier ses informations personnelles
 - **Sécurité :**

- Le système garantit la sécurité des sessions utilisateurs,
- **Interface :**
 - L'utilisateur peut activer un mode sombre.
- **Evaluation et amélioration :**
 - L'utilisateur peut évaluer la qualité des réponses,
 - L'administrateur peut consulter des statistiques d'utilisation.
- **Traçabilité et audit :**
 - **Suivi des activités :**
 - L'administrateur peut consulter les activités des utilisateurs,
 - Le L'administrateur peut consulter les détails d'activité d'un utilisateur,
 - Le système peut filtrer les activités par utilisateur ou type d'action.
 - **Historique :**
 - Le système peut enregistrer les conversations avec leurs horodatages.
 - **Exportation :**
 - L'administrateur peut exporter les journaux d'activité en JSON, Excel ou PDF.
- **Gestion des réclamations :**
 - **Coté utilisateur :**
 - L'utilisateur peut envoyer une réclamation ,
 - L'utilisateur peut consulter la liste de ses réclamations,
 - L'utilisateur peut filtrer ses réclamations par statut,
 - L'utilisateur peut rechercher une réclamation,
 - L'utilisateur peut consulter le détail d'une réclamation,
 - peut voir la progression de sa réclamation.
 - **Coté administrateur :**
 - L'administrateur peut consulter toutes les réclamations,
 - L'administrateur peut filtrer les réclamations par statut, catégorie ou urgence ,
 - L'administrateur peut rechercher une réclamation ,
 - L'administrateur peut consulter une réclamation,
 - L'administrateur peut répondre à une réclamation.
- **Notifications :**
 - L'utilisateur peut recevoir une notification lorsqu'un document est indexé,
 - L'utilisateur peut recevoir une notification lors du réponse d'une réclamation.

IV.2 Besoins non fonctionnels

- **Traçabilité :**
 - Les réponses doivent être accompagnées des références documentaires utilisés,
 - Les actions des utilisateurs doivent être enregistrer pour l'audit.
- **Ergonomie et utilisabilité :**
 - Interface doit être intuitive et simple à l'utilisation,
 - Les réponses doivent être claires, structurées et compréhensibles.
- **Maintenabilité :**
 - Le système doit être permettre l'ajout et la suppression de document sans interruption majeur,
 - L'architecture doit être modulaire pour faciliter la mise à jour.
- **Fiabilité :**
 - Le système doit garantir la disponibilité continue du service,
 - Les réponses générées doivent êtres basées exclusivement sur les documents internes (locale).
- **Confidentialité :**
 - Aucun donné ne doit être transmise vers des services cloud externes ,
 - Le modèle et la base documentaire doivent êtres déployés localement,
 - Les données sensibles doivent être protégées contre tout accès non autorisés.
- **Performance :**
 - La recherche documentaire et la génération de réponses doivent être optimisés pour éviter toute latence excessive,
 - L'indexation des documents doit être réalisé de manière efficace afin de garantir la rapidité pour la recherche

V Choix techniques généraux

Dans cette section , nous présentons l'environnement de développemnt ainsi que les choix technqiues adoptés pour la réalisation du projet. Elle décrit les ressources matérielles utilisées ainsi que les outils et technologies logicielles. Cette partie permet de justifier les choix effectués en fonction des besoins du projet.

V.1 Environnement matériel

Dans cette partie, nous présentons les spécifications matérielles des équipements utilisés dans le cadre du développement du projet.

TABLE 1 – Environnement matériel


Composant	Hp Laptop	MSI Thin GF63
Processeur	Intel Core i5-1334U (13 génération, 1,30 GHz)	Intel Core i5-12450H (12 génération, 2.00 GHz)
RAM	32 Go	32 Go
Stockage	512 Go	512 Go
Carte Graphique	2 Go	4 Go
Système d'exploitation	Windows 11 Famille (Version 10.0.26200)	Windows 11 Pro (Version 25H2)

V.2 Environnement logiciel

Dans le cadre de notre projet, nous avons sélectionné un ensemble de technologies et d'outils en nous basant sur une étude comparative présentée en (annexe 1). Ce choix vise à garantir la performance, la flexibilité et la scalabilité de l'application. Les technologies adoptées ont été regroupées selon leur rôle dans l'architecture du système, notamment les langages de programmation, les frameworks, les bases de données, ainsi que les outils de développement et de déploiement.

- **Framework et bibliothèque utilisés**

TABLE 2 – Framework et bibliothèque

Logo	Technologie	Description
 Figure 1 – Logo FastAPI	FastApi	Framework web performant et moderne en Python, qui facilite la création d'API grace aux annotations de type standard.[1]
 Figure 2 – Logo React	React	Bibliothèque Javascript utilisée pour construire des interfaces utilisateur dynamiques et réactives. Elle repose sur des composants réutilisables et améliore l'expérience utilisateur.[2]
 Figure 3 – Logo Tailwind	Tailwind CSS	Framework CSS utilitaire permettant de concevoir rapidement des interfaces modernes et responsives. il offre des classes prêtes à l'emploi pour styliser les composants sans écrire beaucoup de CSS.[3]

- **Langage de Programmation**

TABLE 3 – Les Langages de Programmation

Logo	Technologie	Description
 Figure 4 – Logo Python	Python	Langage de Programmation polyvalent, largement utilisé dans le développement backend et les applications d'intelligence artificielle. Il offre une syntaxe simple et de nombreuses bibliothèques pour le traitement de données et le machine learning.[4]
 Figure 5 – Logo Javascript	Javascript	Langage de programmation utilisé principalement pour le développement web coté client . Il permet de créer des interfaces interactives et dynamiques dans les applications web.[5]
 Figure 6 – Logo de Typescript	Typescript	Langage basé sur JavaScript qui ajoute le typage statique. Il permet d'améliorer la qualité du code, la détection des erreurs et la maintenabilité des applications complexes.[6]

- Base de données et stockage

TABLE 4 – Les outils de base de données

Logo	Technologie	Description
 Figure 7 – Logo de MongoDB	MongoDB	Base de données NoSQL orientée documents, qui stocke les données sous forme JSON. Elle offre une grande flexibilité pour gérer des données non structurées.[7]
 Figure 8 – Logo de Qdrant	Qdrant	Base de données vectorielle utilisée pour stocker et rechercher des embeddings. Elle permet d'effectuer des recherches sémantiques efficaces dans les systèmes basés sur l'IA.[8]


- Intelligence Artificielle

TABLE 5 – Outil d'IA

Logo	Technologie	Description
 Figure 9 – Logo d'Ollama	Ollama	Plateforme permettant d'exécuter des modèles de langage (LLM) en local. Elle garantit la confidentialité des données et facilite l'intégration de l'IA dans les applications.[9]
 Figure 10 – Logo de llama3	Llama3	[10]

- Outils de développement

TABLE 6 – Outils de développement

Logo	Technologie	Description
 Figure 11 – Logo de VS Code	Vs Code	Éditeur de code léger et puissant, utilisé pour le développement d'applications. Il propose de nombreuses extensions pour améliorer la productivité.[11]
 Figure 12 – Logo de Trello	Trello	Outil de gestion de projet basé sur un système de tableaux et de cartes. Il permet de suivre l'avancement des tâches, organiser le travail en équipe et gérer les sprints de manière visuelle.[12]
 Figure 13 – Logo de Notion	Notion	Outil de gestion et d'organisation permettant de centraliser les notes et la documentation. Il facilite la collaboration et la structuration des informations du projet .[13]


- **Modélisation et Conception**

TABLE 7 – Outils de modélisations et conception

Logo	Technologie	Description
 Figure 14 – Logo de Wire- frame	Wireframe	Un wireframe est un schéma en noir et blanc représentant la structure et l'architecture fonctionnelle d'une page web ou d'une application.[14]
 Figure 15 – Logo de Draw.io	Draw.io	Outil permettant de créer des diagrammes UML, des schémas d'architecture et des représentations visuelles du système.[15]

- **Conteneurisation et système**

TABLE 8 – Outils de conteneurisation et système d’exploitation utilisés

Logo	Technologie	Description
 Figure 16 – Logo de Docker	Docker	Permet de créer des conteneurs isolés et reproductibles pour déployer et gérer facilement l’application .[16]
 Figure 17 – Logo de Ubuntu	Ubuntu	Fournit un environnement serveur stable, sécurisé et compatible pour héberger les applications Dockerisées.[17]

Dans ce premier chapitre, nous avons présenté le cadre générale de projet en introduisant l’organisme d’accueil ainsi que son rôle dans la gestion des systèmes d’information au sein des administrations financières publiques. Nous avons ensuite exposé le contexte et les enjeux liés à la gestion des documents juridiques et réglementaires, en mettant en évidence les difficultés rencontrées dans leur exploitation. L’étude de l’existant a permis d’analyser les méthodes actuellement utilisées ainsi que leurs limites, ce qui a conduit à la formulation de la problématique du projet. Afin de répondre à cette problématique, une solution basée sur un Chatbot intelligent utilisant une approche RAG a été proposée. Par la suite, nous avons défini le périmètre fonctionnel du système à travers l’identification des besoins fonctionnels et non fonctionnels. Enfin, nous avons présenté les choix techniques adoptés ainsi que l’environnement matériel et logiciel utilisé pour la réalisation du projet. Ce chapitre constitue ainsi une base essentielle pour la suite du travail, qui sera consacrée à la conception détaillée et à l’implémentation de la solution proposée.

Chapitre 2 : État de l’art

Ce chapitre présente les principaux concepts liés aux chatbots intelligents et à l’intelligence artificielle conversationnelle. Il couvre les modèles de langage de grande taille (**LLM**) ainsi que les approches de déploiement auto-hébergées. Une attention particulière est portée à la technique RAG, qui combine la recherche d’information et la génération de texte afin d’améliorer la fiabilité des réponses. Ce chapitre fournit les bases théoriques nécessaires à la compréhension du projet.

I Chatbot Intelligent

I.1 Définition et Concepts fondamentaux

Un Chatbot intelligent est un agent conversationnel fondé sur des techniques d’intelligence artificielle, qui comprend et traite le langage naturel des utilisateurs pour formuler des réponses adaptées. Il s’appuie principalement sur des technologies telles que le traitement du langage naturel (**NLP**) pour analyser les requêtes, la génération du langage naturel (**NLP**) pour produire des réponses cohérentes, ainsi que l’apprentissage automatique pour améliorer ses performances au fil des interactions. Ces mécanismes permettent au Chatbot intelligent de comprendre le sens et le contexte des conversations et d’évoluer progressivement grâce à l’expérience acquise.[18]

I.2 Chatbot classique et Chatbot intelligent

La différence entre un Chatbot classique et un Chatbot intelligent réside avant tout dans leur aptitude à comprendre et s’adapter. Le Chatbot classique fonctionne sur la base de règles et de scénarios prédéfinis, en utilisant le plus souvent des techniques de correspondance de mots-clés. Cette approche restreint sa capacité à gérer des requêtes complexes ou imprévues. A l’inverse, le Chatbot intelligent s’appuie sur des techniques avancées d’intelligence artificielle, notamment le traitement du langage naturel et l’apprentissage automatiques, ce qui lui permet de comprendre le sens des requêtes, de tenir compte du contexte conversationnel et d’adapter dynamiquement des réponses. Il peut, en outre, perfectionner ses performances au cours du temps, en s’apprenant à partir des échanges avec les utilisateurs.[19]

TABLE 9 – Différence entre Chatbot classique et Chatbot intelligent

Critère	Chatbot classique	Chatbot intelligent
Fonctionnement	Basé sur des règles fixes et scripts	Basé sur l'intelligence artificielle
Compréhension	Correspondance de mots-clés	Compréhension du langage naturel
Contexte	Non pris en compte	Pris en compte
Adaptabilité	Faible	Élevée
Apprentissage	Aucun	Apprentissage automatique
Complexité	Requêtes simples	Requêtes complexes

I.3 Comparaison des différents types de Chatbots et de leur évolution technologique

La comparaison des différents types de Chatbots et de leur évolution technologique repose sur plusieurs critères liés à leur fonctionnement, leur capacité de compréhension et leur niveau d'intelligence. Le tableau suivant présente une synthèse des principales caractéristiques des Chatbots, depuis les premiers systèmes comme ELIZA jusqu'aux modèles avancés tels que ChatGPT en se basant sur des critères.

TABLE 10 – Evolution des Chatbots : de ELIZA à ChatGPT

Critère	ELIZA	SmarterChild	Siri	ChatGPT
Année d'apparition	1966	2001	2011	2022
Approche	Basée sur des règles	Règles + base de données	IA + NLP+ reconnaissance vocale	IA générative (LLM)
Compréhension du langage	Très limitée	Limitée	Avancée	Très avancée
Type de réponse	Reformulation de phrases	Réponses prédéfinies	Réponses contextuelles	Réponses générées dynamiquement
Apprentissage	Aucun	Aucun	Limité	Apprentissage à grande échelle
Interaction	Textuelle	Textuelle	Vocale et textuelle	Multimodale
Capacité décisionnelle	Non	Très limitée	Oui (actions simples)	Oui (raisonnement et assistance)
Domaine de connaissance	Très restreint	Restreint	Général + services système	Très large et multi-domaines
Objectif principal	Simulation de dialogue	Fourniture d'informations	Assistant personnel	Assistant conversationnel intelligent
Type de Chatbot	Classique	Classique amélioré	Intelligent	Intelligent avancé

II Approche Auto-hébergée

II.1 Définition de l'approche auto-hébergée

L'approche auto-hébergée (self-hosting) correspond à un modèle de déploiement par lequel une organisation ou un individu héberge, exécute et administre ses applications et services sur une infrastructure dont il a la mainmise directe. Ce modèle autorise une gestion autonome des ressources et un contrôle accru sur les données, la sécurité et la configuration des systèmes, contrairement aux solutions de Cloud Computing où ces éléments sont gérés par des fournisseurs tiers.

II.2 Comparaison entre Auto-hébergée et Cloud

Le choix entre une approche auto-hébergée et une solution Cloud repose sur plusieurs critères techniques, organisationnels et économiques . Le tableau suivant présente une comparaison synthétique entre les deux modèles selon les principaux aspects pertinents pour un système informatique intelligent.

TABLE 11 – Comparaison entre l’approche auto-hébergée et l’approche Cloud

Critère	Approche auto-hébergée	Approche Cloud
Sécurité	Contrôle total des mécanismes de sécurité et des accès	Sécurité principalement gérée par le fournisseur
Confidentialité	Données conservées en interne	Données hébergées chez un tiers
Souveraineté des données	Maîtrise complète de la location et du traitement des données	Dépendance à la juridiction du fournisseur
Coût	Investissement initial élevé (matériel , maintenance)	Coût variable basé sur l’usage
Maintenance	Assurée par l’organisation	Assurée par le fournisseur Cloud
Scalabilité	Limitée par les ressources internes	Élevée et flexible
Dépendance au fournisseur	Faible dépendance	Forte dépendance au prestataire Cloud

III Modèles de langage de grande taille (LLM)

III.1 Définition des LLM

Un modèle de langage de grande taille est un type de modèle d’intelligence artificielle. Il utilise des techniques d’apprentissage automatique pour traiter et générer du texte. Ce modèle fonctionne en utilisant les probabilités de cooccurrence entre les mots. Cela signifie qu’il regarde comment les mots sont utilisés ensemble dans le langage .

Ce modèle est entraîné sur des quantités énormes de texte. Il apprend à prédire chaque mot d’une séquence en fonction des mots qui viennent avant. Cela lui permet de produire des textes qui ont du sens et qui ressemblent à la façon dont les humains parlent et écrivent. Les textes générés par ce modèle sont souvent très réalistes et difficiles à distinguer de ceux écrits par des humains.[20]

III.2 Entraînement des modèles de langage LLM

L'entraînement des modèles de langage de grande taille est une étape très importante pour leur développement. Cet entraînement a lieu avant de les utiliser et consiste à utiliser de grandes quantités de données textuelles. Ces données proviennent de livres, d'articles scientifiques et de contenus disponibles sur le web.

Le modèle apprend principalement de manière auto-supervisée. Cela signifie qu'il est entraîné pour prédire le mot suivant dans une phrase donnée. Au fur et à mesure de son apprentissage, le modèle comprend les règles de grammaire, les relations entre les mots et les particularités du langage naturel. En analysant un grand nombre de phrases, le modèle devient capable de reconnaître des modèles linguistiques complexes et d'appliquer ses connaissances à de nouvelles situations.

Certaines méthodes incluent également une étape appelée apprentissage par renforcement avec des commentaires humains. Cette étape permet d'améliorer la qualité et la sécurité des réponses générées par le modèle.

L'entraînement est donc une phase cruciale, car il influence directement les performances et les capacités du modèle lorsqu'il est utilisé par la suite.

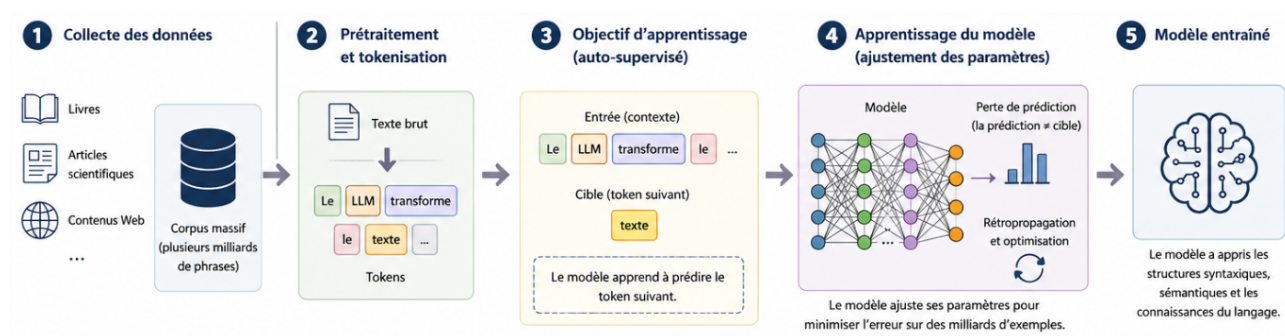


Figure 18 – Entraînement des modèles de langage (LLM)

III.3 Fonctionnement des modèles de langage LLM

Le fonctionnement d'un modèle de langage de grande taille repose sur plusieurs étapes. Ces étapes permettent de transformer une entrée textuelle en une réponse générée automatiquement.

- **Saisie du texte de l'utilisateur** : Le processus commence par la réception d'une entrée textuelle fournie par l'utilisateur. Cette entrée peut être une question ou une instruction.
- **Tokenisation** : Le texte est ensuite divisé en unités élémentaires appelées tokens. Ces tokens peuvent être des mots, des parties de mots ou des caractères. Cette transformation permet de convertir le texte en une représentation que le modèle peut utiliser.

- **Analyse du contexte** : Les tokens sont analysés à l'aide de l'architecture **Transformer** , qui utilise des mécanismes d'attention. Cette étape permet de comprendre les relations entre les tokens et le contexte global de la séquence.
- **Prédiction du token suivant** : Le modèle prédit le token suivant le plus probable en fonction du contexte analysé. Il utilise les probabilités apprises lors de la phase d'entraînement pour faire cette prédiction.
- **Génération de la réponse** : Le processus de prédiction est répété plusieurs fois . Chaque token généré est ajouté à la séquence, permettant au modèle de construire progressivement une réponse. Cette réponse est cohérente et adaptée à la requête initiale de l'utilisateur




Figure 19 – Fonctionnement des modèles de langage LLM

III.4 Présentation des principaux modèles de langage (LLM)

- **ChatGPT** : est un modèle de langage de grande taille créé par OpenAI. Il utilise l'architecture **Transformer** pour produire des textes qui ont du sens et qui sont adaptés au contexte. Pour fonctionner, il a d'abord été entraîné sur des grandes quantités de données, puis il a été amélioré grâce à des méthodes d'apprentissage automatique qui impliquent des retours humains. Cela lui permet de fournir des réponses de meilleure qualité, plus pertinentes et plus fluides. [21]



Figure 20 – Logo ChatGPT

- **Claude** : est un modèle de langage créé par **Anthropic**. Il est conçu pour fournir des réponses fiables et sûres, tout en respectant des principes éthiques stricts. Claude se concentre sur la réduction des biais d'apprentissage supervisé et par renforcement.

Ces méthodes lui permettent de mieux comprendre ce que l'utilisateur veut dire et d'améliorer la qualité des réponses qu'il fournit.[22]



Figure 21 – Logo Claude

- **LLaMA** : est une famille de modèles de langage développée par Meta. Ces modèles sont conçus pour offrir un bon équilibre entre performance et efficacité en termes de calcul. Contrairement à certains modèles qui appartiennent à des entreprises privées, LLaMA est conçu pour être plus accessible et adaptable. Cela signifie qu'il peut être utilisé dans des situations où les ressources informatiques sont limitées ou lorsqu'il est nécessaire de l'installer localement .[23]



Figure 22 – Logo Claude

III.5 Utilisation des LLM dans les systèmes conversationnels

Les modèles de langage de grande taille comme ChatGPT, Claude et LLaMA ont des architectures similaires. Mais ils sont différents en termes d'objectifs, de performances et de domaines d'application. Plusieurs études académiques ont examiné ces différences. Elles ont mis en évidence des variations en termes de fiabilité, de flexibilité et d'orientation d'usage.

Table 12 – Comparaison des modèles de langage ChatGPT, Claude et LLaMA

Critère	ChatGPT	Claude	LLaMA
Fonctionnalités	Offre une génération de contenu dynamique et cohérent	Se caractérise par une génération fiable et sécurisée	présente une flexibilité et une adaptabilité notables, ainsi que la possibilité d'un déploiement local
Méthodologie d'entraînement	entraîné à partir de données massives et utilise la rétroaction humaines pour améliorer ses performances	entraîné en utilisant une approche de rétroaction humaine orientée sécurité	a bénéficié d'un pré-entraînement optimisé pour améliorer ses capacités
Performance	offre une haute fluidité et sa cohérence	se distingue par sa fiabilité et sa cohérence	présente une bonne performance, mais celle-ci peut varier en fonction de la configuration
Précision des résultats	offre une précision élevée, mais peut parfois commettre des erreurs	très fiable et commet moins d'erreurs	présente une précision variable, dépendant du réglage utilisé
Cas d'utilisation	est bien adapté pour les services client et les assistants virtuels	convient particulièrement aux domaines de la santé, de l'éducation et des domaines sensibles	est approprié pour les environnements à ressources limitées, les applications mobiles et IoT

IV RAG(Retrieval-Augmented Generation)


IV.1 Définition du RAG

La génération augmentée de récupération (Retrieval-Augmented Generation) est une méthode qui consiste à ajouter une étape de recherche d'informations pour extraire des contenus pertinents à partir d'un corpus documentaire. Le RAG utilise ces informations combinées à la requête de l'utilisateur pour permettre au modèle de LLM de générer une réponse plus précise et plus contextualisée.[24]

IV.2 Principe de fonctionnement d'un système RAG

Un système de RAG fonctionne selon une architecture à plusieurs étapes, qui permet de transformer une requête utilisateur en une réponse contextualisée. Ce processus intègre des mécanismes de recherche d'information et de génération de texte, permettant d'exploiter des sources externes pertinentes. On peut le décrire par trois étapes principales. Ces étapes sont détaillées comme suit :

Figure 23 – Schéma de fonctionnement d'un système RAG



IV.2.1 Requête utilisateur

Le processus débute lorsqu'un utilisateur soumet une question ou une instruction en langage naturel via une interface applicative(application web, Chatbot ou API). Cette requête exprime un besoin informationnel précis, souvent lié à un domaine particulier.

IV.2.2 Recherche documentaire (Retrieval)

La requête utilisateur est transformée en une représentation est ensuite comparée aux vecteurs des documents stockés dans une base vectorielle afin d'identifier les contenus les plus proches sur le plan sémantique. Les documents les plus pertinents (**top-k**) sont alors sélectionnés pour constituer le contexte qui sera utilisé lors de la génération de la réponse.

IV.2.3 Génération de la réponse (Generation)

Les documents récupérés sont ensuite intégrés au prompt du modèle de langage (**LLM**), en complément de la requête initiale. Le modèle de langage utilise ensuite ces informations pour générer une réponse plus précises et mieux adaptée au contexte. Cette approche permet non seulement d'améliorer la pertinence des réponses , mais aussi de limiter les risques d'hallucinations en se basant sur des sources réelles.

IV.3 Composants d'un système RAG

Un système repose sur plusieurs composants clés, chacun jouant un rôle spécifique dans la chaîne de traitement.

IV.3.1 Les documents

Les documents sont la source de connaissance externe du système RAG. Ils peuvent être de nature différente :

- Document PDF,
- Pages web,
- Bases de connaissances internes,
- Fichiers texte ou bases de données structurées.

Ces documents passent par une phase de prétraitement, comprenant le nettoyage, la normalisation et le découpage en fragments (chunking), avant leur exploitation. Ce découpage permet d'assurer une granularité adaptée lors de la recherche d'information.

IV.3.2 Les embeddings

Les embeddings sont des représentations vectorielles denses qui permettent de transmettre le sens sémantique des textes. Ils sont produits à partir de modèles spécialisés (comme ceux de la famille des Sentence Transformers ou via des API d'embeddings). On transforme chaque fragment du document en un vecteur numérique de dimension fixe. De la même manière, la requête de l'utilisateur est encodée dans le même espace vectoriel, ce qui permet de mesurer la similarité sémantique entre la question et les documents.

IV.3.3 La base vectorielle

La base vectorielle constitue une pièce essentielle du système RAG. Cela permet de stocker, indexer et interroger efficacement un grand volume d'embeddings. Elle est optimisée pour des recherches par similarité (par exemple via la similarité cosinus), contrairement aux bases de données classiques. Des solutions comme Qdrant, FAISS ou Pinecone sont couramment utilisées. Elles assurent de courts temps de réponse même à partir de gros corpus, ce qui est indispensable pour une utilisation en temps réel.

IV.3.4 Le LLM (Large Language Model)

Le LLM est responsable de la génération finale de la réponse. Contrairement à un usage classique où le modèle s'appuie uniquement sur sa connaissance interne, le LLM dans un système RAG est guidé par un contexte externe fourni dynamiquement. Ce mécanisme permet :

- Améliorer la précision des réponses,
- Dédire les hallucinations,
- Actualiser facilement la base de connaissances sans réentraîner le modèle.

Le LLM agit ainsi comme un moteur de synthèse intelligent, capable de reformuler et de structurer l'information extraite des documents.